(1)

1) FLOPS

$$F_{conv} = 2 \cdot B \cdot H_{out} W_{out} C_{out} \cdot C_{in} \cdot k^2$$

$$F_1 = 2B \left(\frac{S}{2}\right)^2 (32)(3)(7^2) = 2352\,BS^2$$

$$F_2 = 2B \left(\frac{S}{4}\right)^2 (64)(32)(5^2) = 6400\,BS^2$$

$$F_3 = 2B \left(\frac{S}{8}\right)^2 (128)(64)(3^2) = 2304\,BS^2$$

$$F_4 = 2B \left(\frac{S}{8}\right)^2 (256)(128) = 1024\,BS^2$$

$$F_5 = 2B \left(\frac{S}{16}\right)^2 (256)(256)(3^2) = 4608\,BS^2$$

$$F_6 = 2B \left(\frac{S}{16}\right)^2 (512)(256) = 1024\,BS^2$$

$$F_{fc1} = 2B\,(512)(256) = 262144\,B$$

$$F_{fc2} = 2B\,(256)(100) = 51200\,B$$

$$FLOPs(S, B) = B\left(17712S^2 + 313344\right)$$

2) Память

$$N_{conv} = 4704 + 51200 + 73728 + 32768 + 589824 + 131072 = 883296$$

Linear:

$$N_{Lin} = 512 \cdot 256 + 256 + 256 \cdot 100 + 100 = 157028$$

$$N_{params} = 883296 + 157028 = 1040324$$

$$M_{params} = 4 \cdot 1040324 = 4161296 \text{ bytes}$$

Пик активации на первой свёртке:

$$N_{input} = 3BS^2$$

$$N_{output} = 32B\left(\frac{S}{2}\right)^2 = 8BS^2$$

$$N_{peak} = 3BS^2 + 8BS^2 = 11BS^2$$

$$M_{act} = 4 \cdot 11BS^2 = 44 \cdot BS^2$$

$$Memory(S, B) = 416196 + 44BS^2$$

Условие ООМ: $Memory(S, B) > M_{GPU}$

* не учитывал сюда context, округление аллокатора, резерв memory

3) Bytes moved

I каждый оператор один раз читает вход и параметры и один раз записывает выход. in place ReLU читает и записывает активацию.

$$Q_1 = (3 + 8 + 16 + 8 + 2)BS^2 = 37BS^2$$

$$Q_2 = (2 + 4 + 8)BS^2 = 14BS^2$$

$$Q_3 = (4 + 2 + 4)BS^2 = 10BS^2$$

$$Q_4 = (2 + 4 + 8)BS^2 = 14BS^2$$

$$Q_5 = (4 + 1 + 2)BS^2 = 7BS^2$$

$$Q_6 = (1 + 2 + 4)BS^2 = 7BS^2$$

$$Q_{GAP,\ input} = 2BS^2$$

$$Q_{head} = (512 + 768 + 512 + 356)\,B = 2148\,B$$

$37 + 14 + 10 + 14 + 7 + 7 + 2 = 91$

С учётом чтения параметров:

$$Q(S, B) = 4(91\,BS^2 + 2148\,B + 1040324)$$

4) Latency

$$N = 6\,Conv + 7\,ReLU + 1\,MaxPool + 1\,GAP + 2\,Lin = 17$$

$$\theta = (L, P, W)$$

- L — время одного запуска ядра
- P — эффективная производительность, FLOP/s
- W — эффект. пропускная способность, byte/s

$$T_{launch} = 17L$$

$$T_{compute} = FLOPs(S, B) / P$$

$$T_{memory} = Q(S, B) / W$$

$$Latency(S, B, \theta) = 17L + \max\left(\frac{FLOPs(S, B)}{P}, \frac{Q(S, B)}{W}\right)$$

Для RTX 5060:

$$L = 1{,}61895 \cdot 10^{-5}\ s$$

$$P = 5{,}60119 \cdot 10^{12}\ FLOP/s$$

$$W = 1{,}27743 \cdot 10^{11}\ byte/s$$

3) Energy

1. энергия всей GPU
   - idle energy не вычитывается
   - энергия серии forward pass делится на число запусков
   - все коэф. не отрицательные

$$\theta_E = (P_0, e_F, e_Q, \theta)$$

$$Energy(S, B, \theta_E) = P_0 \cdot Latency(S, B, \theta) + e_F \cdot FLOPs(S, B) + e_Q \cdot Q(S, B)$$

после калибровки:

$$P_0 = 57{,}461 \text{ W}$$

$$e_F = 1{,}69419 \cdot 10^{-11} \text{ J/FLOP}$$

$$e_Q = 1{,}00505 \cdot 10^{-15} \text{ J/byte}$$

6) Решения

Launch-bound:

$$I_{TL} > \frac{FLOPs}{P} \qquad I_{TL} > \frac{Q}{W}$$

Memory-bound:

$$\frac{Q}{W} > I_{TL} \qquad \frac{Q}{W} > \frac{FLOPs}{P}$$

Compute-bound:

$$\frac{FLOPs}{P} > I_{TL} \qquad \frac{FLOPs}{P} > \frac{Q}{W}$$